

BE : INTRODUCTION À LA GÉOMÉTRIE DE L'INFORMATION OU COMMENT CALCULER POUR COMPRENDRE POURQUOI ON SE TROMPE.

Consignes Générales :

- *Par groupe de 5 à 6 étudiants maximum, vous devez rédiger un rapport dans lequel vous répondrez aux questions du sujet et plus globalement au problème demandé. La qualité de rédaction ainsi que tous les compléments que vous apporterez (réflexions, analyses des réponses, tests sur d'autres données, etc...) seront fortement pris en compte. Ce rapport devra être rédigé sous un traitement de texte (les pages manuscrites ne sont pas acceptées) et rendu sous la forme d'un fichier .pdf.*
- *Toutes les fonctions programmées le seront en Python et seront abondamment commentées. Le rendu du projet se fera sous la forme d'un fichier .zip contenant le rapport ainsi que l'ensemble des programmes et données nécessaires à l'exécution des programmes.*
- *Les fonctions programmées doivent l'être dans un fichier librairie ayant pour nom : **Ma315_BE_lib.py**. Dans ce fichier les différentes fonctions doivent être regroupées dans des blocs (commande : #%%) correspondants aux parties du sujet.*
- *Les applications numériques des fonctions du sujet seront dans un fichier ayant pour nom : **Ma315_BE_main.py**. Dans ce fichier les différents cas d'étude doivent être regroupés dans des blocs séparés.*
- *Les différentes données utilisées devront être enregistrées dans un dossier ayant pour nom **Data**. Ce dossier doit être mis dans le même répertoire que vos fichiers **Ma315_BE_lib.py** et **Ma315_BE_main.py**.*
- *Les noms des différents membres du groupe doivent apparaître en commentaire en début de fichier.*
- *Le non-respect des consignes précédentes entraînera des points de pénalité pouvant être conséquents...*
- *Concernant Python, le rendu attendu est l'utilisation des fonctions de bases des librairies Numpy, Matplotlib et OpenCV. Néanmoins l'utilisation de fonctions plus avancées qui améliorent les rendus graphiques par exemple et/ou la programmation en terme de classe seront bien évidemment acceptées et seront valorisées.*
- *Les questions d'analyse de résultats sont généralement ouvertes. La qualité de vos réflexions sera fortement prise en compte pour la notation de ces questions.*
- **Il est impératif de lire le sujet en entier.**
- **Enfin on rappelle qu'un BE est un examen et comme tout examen il arrive de ne pas pouvoir répondre à toutes les questions.**

Le projet proposé suit deux buts principaux : donner une introduction à la géométrie de l'information, on obtient un point de vue différent sur les probabilités et les statistiques (en espérant que cet autre point de vue réconcilie un peu les plus récalcitrants aux statistiques...) et proposer une sorte de « laboratoire » d'épistémologie quantitative. Dans ce bureau d'étude nous allons réfléchir aux biais de cognitions et plus généralement voir par le calcul pourquoi on est souvent conduit à des erreurs de raisonnement. Nous prendrons la géométrie de l'information comme une sorte de modèle normatif de la rationalité face à de l'information à traiter et nous verrons en quoi cela peut nous éclairer et nuancer nos raisonnements. La longueur (en page) du sujet s'explique pour plusieurs raisons :

- la présence de nombreux encart « Pause épistémologique », détaillant des biais cognitifs ou des remarques liés aux formalismes introduit. Certains de ces biais ou remarques pourraient s'appliquer à plusieurs questions du sujet, pour ne pas alourdir nous ne les répéterons pas (à vous d'identifier les différentes expressions formelles d'un même biais).
- les questions sont souvent très découpées et les réponses sont souvent rapides.
- les questions de statistiques et de probabilités demandent souvent un long « contexte » pour être formulées correctement.

La spécificité de ce sujet est de traiter de biais cognitif de manière formelle et quantitative. En mobilisant vos connaissances diverses, une consigne générale sera de produire des exemples sourcés des différents biais et de regarder les réponses apportées par la formalisation du sujet.

Attention les sujets et thèmes abordés ne le sont qu'en surface et il y aurait beaucoup (trop) de choses à dire sur de nombreux points. Vos ouvertures personnelles (en lien avec le sujet bien sûr !) et réflexions seront fortement valorisées.

Notations globales : Dans ce BE nous nous intéresserons aux distributions de probabilités finies. On identifiera souvent les univers Ω aux ensembles finis de la forme :

$$\{1, \dots, n\}$$

pour un entier $n \geq 1$ et une distribution de probabilité à un n -vecteurs :

$$p := (p_1, \dots, p_n)$$

tel que :

$$\sum_{i=1}^n p_i = 1$$

Pour $n \geq 1$, on notera l'ensemble des distributions sur $\{1, \dots, n\}$:

$$\Delta_n := \{p \text{ est une distribution de probabilité sur } \{1, \dots, n\}\}$$

On appelle cet ensemble un n -simplexe. Géométriquement c'est l'enveloppe convexe des vecteurs de la base canonique $(e_i)_{i \in \llbracket 1, n \rrbracket}$, où e_i est le vecteur dont la seule composante non nulle est la i -ème composante valant 1. Par convention on définit :

$$\Delta_0 := \emptyset$$

On notera également le support d'une distribution p :

$$\text{supp}(p) := \{i \in \{1, \dots, n\} \text{ tel que } : p_i > 0\}$$

Lorsque pour $p \in \Delta_n$: $\text{Card}(\text{supp}(p)) = n$, nous dirons que p a un **support plein** et on notera l'ensemble des distributions à support plein de Δ_n : $\mathring{\Delta}_n$. C'est l'intérieur (au sens topologique) de Δ_n i.e :

$$\mathring{\Delta}_n := \{p \in \Delta_n \mid p_i > 0 \forall i \in \llbracket 1, n \rrbracket\}$$

Enfin, car elle aura un rôle important notons u_n la distribution uniforme discrète sur $\{1, \dots, n\}$:

$$u_n := \left(\frac{1}{n}, \dots, \frac{1}{n}\right) \in \Delta_n$$

C'est le « centre » du simplexe Δ_n .

1 L'entropie et compagnies

1.1 Quantité d'information d'un évènement

Supposons que l'on regarde un évènement, par exemple : « il va pleuvoir demain » et que l'on associe à cet évènement une probabilité, disons 40% de chance d'avoir de la pluie. La question est alors quelle information donne le fait que cet évènement se réalise bien le lendemain. Répondre à cette question revient à définir la **quantité d'information d'un évènement de probabilité** $p \in]0, 1]$. Essayons de définir formellement cela. Une notion d'information raisonnable doit donc être une fonction : $I :]0, 1] \rightarrow \mathbb{R}$ et vérifier à minima deux propriétés naturelles : plus un évènement est improbable plus sa réalisation doit être porteur d'information et l'information contenue par deux évènements indépendants doit être la somme des informations contenues par chacun des évènements. Formellement cela revient à demander/postuler les deux propriétés suivantes :

- **Décroissance stricte** : Si $p < q$ alors : $I(p) > I(q)$. Cette propriété traduit le fait qu'un évènement moins probable doit apporter plus d'information qu'un évènement plus probable.



Pause épistémologique : Le biais rétrospectif. C'est une propriété qui semble évidente mais elle permet de réfuter l'attitude classique après une catastrophe ou un évènement rare, le fameux : « C'était évident, je le savais ! » de certain « experts ». En effet :

- si l'expert « le savait », la probabilité subjective (pour l'expert) de l'évènement aurait été de $p \simeq 1$.
- donc, par décroissance, l'information reçue lors de l'évènement serait « nulle ».
- Or si l'évènement a conduit cet expert à changer ses procédures (ou l'a choqué), c'est que l'information portée par l'évènement n'était pas nulle.
- Conclusion : il ne le savait pas ($p < 1$). Une chose évidente n'apprend rien (d'un point de vue informationnel), prétendre le contraire serait malhonnête intellectuellement.

- **Additive** : $I(pq) = I(p) + I(q)$. Elle exprime une exigence minimale de cohérence : l'information portée par la réalisation conjointe de deux événements doit être égale à la somme des informations apportées par chacun d'eux, dès lors que leurs probabilités se combinent multiplicativement, en particulier si ces événements sont indépendants.



Pause épistémologique : L'illusion narrative ou le sophisme de l'addition naïve des informations. Cette propriété est « l'antidote » au **biais de conjonction** qui consiste pour le cerveau humain à souvent juger une histoire détaillée plus crédible/vraisemblable qu'une histoire courte. En effet pour deux événements A et B on a :

- Cas indépendants : $P(A \cap B) = P(A)P(B) \rightarrow I(P(A \cap B)) = I(P(A)) + I(P(B))$
- Cas dépendants : $P(A \cap B) = P(A)P(B|A) \rightarrow I(P(A \cap B)) = I(P(A)) + I(P(B|A))$

Or (et c'est le piège) s'il n'y a pas indépendance de A et B on peut avoir : $P(B|A) > P(B)$ (ou l'inverse). Une illustration historique classique a été produite par Tversky et Kahneman en 1983^a sous la version classique, appelé **paradoxe de Linda**. Il repose sur la confusion entre :

- la cohérence narrative d'un scénario,
- et sa probabilité (et par suite l'information contenue par ce scénario).

Voici le scénario proposé par Tversky et Kahneman : *Linda a 31 ans, elle est célibataire, franche et très brillante. Elle possède une maîtrise de philosophie. Étudiante, elle se montrait très préoccupée par les questions de discrimination et de justice sociale, elle participait aussi à des manifestations antinucléaires.*

Les auteurs ont alors soumis la question suivante à des participants (y compris des étudiants en statistique avancée) : quel scénario jugez-vous plus probable :

- Scénario A : Linda est guichetière dans une banque,
- Scénario B : Linda est guichetière dans une banque et active dans le mouvement féministe.

La grande majorité des participants (85%-90%) ont jugé le scénario B plus probable que le scénario A. Pourtant c'est une violation flagrante de la règle de base des probabilités :

$$P(A \cap B) \leq P(B) \rightarrow I(A \cap B) \geq I(B)$$

Conclusion : une histoire plus riche en détails est nécessairement plus coûteuse en information, même si elle est psychologiquement plus convaincante. Raisonner correctement impose de dissocier : ce qui explique mieux, de ce qui est plus probable. La règle additive interdit de "récompenser" cognitivement un scénario parce qu'il est plus narratif. Elle rappelle qu'en matière d'incertitude, chaque condition ajoutée est un engagement informationnel supplémentaire, et doit être « payée » en probabilité.

^aDaniel Kahneman (dir.), Paul Slovic (dir.) et Amos Tversky (dir.), *Judgment under Uncertainty : Heuristics and Biases*, Cambridge, Cambridge University Press, 1982

Nous allons démontrer que nécessairement I est de la forme : $I(p) = -c \ln(p)$, où $c \geq 0$. Ainsi la quantité d'information possède une mesure « universelle » (à une constante multiplicative près).

1. Que vaut nécessairement $I(1)$?
2. Montrer que l'on peut trouver une fonction : $f : [0, +\infty[\rightarrow \mathbb{R}$ vérifiant les deux propriétés suivantes :
 - a) Pour tout $p \in]0, 1]$, il existe $x \in [0, +\infty[$ tel que : $f(x) = p$.
 - b) et en posant $J(x) := I(f(x))$, l'équation d'additivité devient pour tout $(x, y) \in [0, +\infty[^2$:

$$J(x + y) = J(x) + J(y)$$

3. Montrer que cette fonction J est croissante et $\mathbb{Q}_+$ -linéaire.
4. Nous allons démontrer qu'en réalité J est $\mathbb{R}_+$ -linéaire. Pour cela nous allons utiliser la densité de $\mathbb{R}$ i.e la propriété suivante¹ : soit $x \in [0, +\infty[$, il existe deux suites de rationnels (positifs) : (r_n) et (s_n) telles que :
 - a) (r_n) est une suite croissante convergeant vers x .
 - b) (s_n) est une suite décroissante convergeant vers x .

En utilisant les questions précédentes montrer que :

$$J(x) = J(1)x$$

5. Dédurre de la question précédente que nécessairement :

$$I(p) = -c \ln(p)$$

où $c > 0$ est une constante arbitraire. Ce qui démontre le résultat attendu.

¹Cette propriété sera admise, elle découle simplement de la construction des réels à partir des rationnels. Un réel est formellement une classe d'équivalence de suites de Cauchy de rationnels.

6. En déduire qu'il existe un $b \in \mathbb{R}$ tel que :

$$I(p) = -\log_b(p)$$

Ainsi on retrouve dans la pratique, suivant le contexte, des choix plus « naturels » de base du logarithme pour « mesurer l'information ». Par exemple on utilise souvent le logarithme de base 2 en informatique ou théorie de l'information classique et $b = e^{\frac{1}{k_B}}$ en thermodynamique où k_B est la constante de Boltzmann.

Convention : Dans la suite nous prendrons $c = 1$ car cette constante n'a aucun contenu probabiliste, elle fixe uniquement l'unité de mesure de l'information i.e :

$$I(p) = -\ln(p)$$

Et l'on prendra comme convention :

$$I(0) := +\infty$$

Un évènement impossible ($p = 0$) possède une quantité d'information infinie. C'est la traduction formelle du : si demain une chose que l'on pense impossible se réalise, cela serait une véritable révolution.



Pause épistémologique : La Règle de Cromwell. La convention précédente est la traduction épistémologique de cette règle qui stipule qu'un agent rationnel ne doit attribuer une probabilité égale à 0 à une hypothèse empirique que si elle est logiquement impossible en un sens très fort. Il faut toujours garder un "epsilon" d'incertitude pour ne pas être dogmatique. Formellement pour un évènement H tel que $P(H) = 0$ i.e portant une information « infinie », on a pour toute observation E :

$$P(H|E) = 0$$

i.e. aucune « mise à jour » de mon expérience ne pourra modifier ma non croyance en H ou pour le dire autrement : un dogme est invincible aux preuves.

1.2 Entropie de Shannon

On fixe donc :

$$I(p) := -\ln(p)$$

pour $p \in]0, 1]$.

Soit Ω un espace probabilisé fini (muni de la tribu totale $\mathcal{P}(\Omega)$). Soit X une variable aléatoire sur Ω . On rappelle que la donnée d'une telle variable aléatoire revient à se donner une distribution de probabilité sur Ω . On prendra pour simplifier : $\Omega := \{1, \dots, n\}$ et on notera classiquement pour tout $i \in \Omega$:

$$p_i := P(X = i)$$

On définit alors la variable aléatoire (discrète finie) I_X associée à X par :

$$I_X(i) := \begin{cases} -\ln p_i & \text{si } p_i \neq 0 \\ 0 & \text{sinon} \end{cases}$$

Ainsi I_X mesure la quantité d'information d'un évènement i pour la distribution X lorsque $p_i \neq 0$ (avec la convention formelle pour éviter la divergence de la formule que cette variable aléatoire est nulle si $p_i = 0$, attention I_X est une v.a.r qui modélise la quantité d'information).

On définit l'entropie (au sens de Shannon) de X :

$$H(X) := E(I_X) = -\sum_{i=1}^n p_i \ln(p_i)$$

où l'on fait l'abus de notation (convention) :

$$0 = 0 \ln(0)$$

afin d'avoir une formule homogène même dans le cas où certains p_i sont nuls. En d'autres termes l'entropie est l'information moyenne (i.e pondérée par les probabilités) contenue dans une valeur $x_i := X(i)$ de X . En effet on rappelle que l'espérance est la valeur moyenne que l'on peut espérer obtenir lors d'une réalisation de la variable aléatoire considérée. Une autre façon de dire cela est que **l'entropie est une mesure du coût informationnel moyen d'une observation tirée selon la loi X considérée et donc forme une mesure de notre ignorance résiduelle moyenne.** Pour que l'entropie soit « grande » il faut des variables aléatoires qui peuvent prendre de « nombreuses » valeurs « plausibles » i.e ayant des p_i nombreux non nuls et proche l'un de l'autre en valeur.

Afin de regarder les propriétés de la fonction d'entropie, comme une v.a. discrète X s'identifie avec une distribution de probabilité on peut voir H comme une fonction à n variables en posant :

$$p := (p_1, \dots, p_n)$$

et :

$$H(p) := H(X) = - \sum_{i=1}^n p_i \ln(p_i)$$

1. Montrer que H est concave. Ainsi si l'on « mélange » deux lois de probabilité, l'entropie du mélange est supérieure ou égale à la moyenne pondérée des entropies des lois d'origine.



Pause épistémologique : Le Sophisme du Juste Milieu (Argumentum ad temperantiam). La concavité mathématique de l'entropie :

$$H(\lambda p + (1 - \lambda) q) \geq \lambda H(p) + (1 - \lambda) H(q)$$

illustre formellement le danger du "compromis mou". En effet en l'absence de certitude absolue sur le modèle à choisir (loi p ou loi q), le « mélange » des hypothèses (la moyenne des distributions) génère toujours une entropie (une incertitude) plus grande que la moyenne des certitudes individuelles. C'est une traduction formelle de l'humilité épistémique : refuser de trancher arbitrairement entre deux théories concurrentes augmente notre incertitude globale à court terme, mais préserve mieux l'information que de choisir dogmatiquement l'une ou l'autre. Si deux experts très sûrs d'eux ont des opinions contradictoires, le réflexe (biais) classique de « couper la poire en deux » en faisant par exemple la moyenne des deux avis produit un coût informationnel important : la moyenne arithmétique de deux vérités précises n'est pas une vérité nuancée, c'est un brouillard incohérent (on augmente l'incertitude). En voulant satisfaire tout le monde par le calcul moyen, on peut se retrouver à augmenter la confusion. Ainsi : « la vérité est au milieu » : est un sophisme, que l'on retrouve également sous le nom de **sophisme du compromis**, montre dans son cas général, que les synthèses peuvent « diluer » l'information. Nous verrons plus tard (avec l'étude des géodésiques) une expression quantitative de cela.

2. Soient X et Y deux v.a. discrètes ayant comme supports respectifs $\Omega_X := \{x_i \in \mathbb{R} \mid i \in \llbracket 1, n \rrbracket\}$ et $\Omega_Y := \{y_i \in \mathbb{R} \mid i \in \llbracket 1, m \rrbracket\}$. On rappelle que :

- la loi de la distribution conjointe, notée (X, Y) est donnée par :

$$p_{ij} = P(X = x_i, Y = y_j) = P(\{X = x_i\} \cap \{Y = y_j\})$$

pour tout $(x_i, y_j) \in \Omega_X \times \Omega_Y$.

- la loi de distribution conditionnelle, notée $(X|Y)$ et définie par :

$$P(X = x_i | Y = y_j) = \frac{P(\{X = x_i\} \cap \{Y = y_j\})}{P(Y = y_j)} = \frac{p_{ij}}{q_j}$$

avec $q_j := P(Y = y_j)$.

Montrer que :

$$H(X, Y) = H(Y) + H(X|Y)$$

où (X, Y) est la distribution conjointe de X et Y . Cette propriété traduit l'idée que l'information totale peut se décomposer en une information « primaire » plus une information conditionnelle.

3. Calculer l'entropie (à la main ou numériquement) pour les lois discrètes finies usuelles : loi de Bernoulli, loi uniforme discrète, loi binomiale, loi de Newcomb-Benford et distribution de Boltzmann (cf principe MaxEnt). Pour les lois à paramètres on fera varier celui-ci en regardant l'influence des paramètres sur l'entropie. En utilisant le fait que l'entropie est une mesure de notre ignorance moyenne résiduelle interpréter les résultats obtenus.
4. Python : En utilisant la fonction *histogram* de Numpy ou de Matplotlib, calculer l'entropie de la distribution des couleurs d'images. On raisonnera par couche couleurs ou en niveau de gris. On rappelle que l'intensité des couleurs est codée par des entiers (uint8) de 0 à 255, on fera l'histogramme sur ce support. Donner des exemples d'images avec une faible, moyenne et forte entropie. Analyser le résultat obtenu.
5. Ouverture : **la varentropie**. Si l'entropie est l'espérance de I_X , calculons la stabilité de cette incertitude moyenne i.e sa variance. On appelle **varentropie** la variance de I_x :

$$V(X) := \text{Var}(I_X)$$

Calculer la varentropie pour les lois finies usuelles. Analyser les résultats obtenus. Tester numériquement la varentropie sur les mêmes images qu'à la question précédente.

6. Soit une suite de variables aléatoires i.i.d $(X_1, \dots, X_n)$ suivant une loi X de distribution noté $p \in \Delta_n$. Montrer que la variable « information totale reçue » :

$$I_{total}^{(n)} := \sum_{i=1}^n I_{X_i}$$

suit une loi normale (que vous préciserez) lorsque n est « grand ».



Pause épistémologique : L'Illusion de la Stabilité et le Problème de la Dinde. L'analyse conjointe de l'entropie (H) et de la varentropie (V) donne une formulation mathématique rigoureuse au "Problème de la Dinde" du statisticien Nassim Taleb dont voici l'histoire : « Pendant 1000 jours, le fermier nourrit la dinde. Chaque jour qui passe apporte une information quasi-nulle ("Rien à signaler, la vie est belle"). L'entropie « historique » est très faible. La dinde, statisticienne naïve qui se fie à la moyenne, voit sa confiance augmenter chaque jour : "Mon monde est stable, sûr, et le fermier m'aime." Le 1001ème jour (Thanksgiving), le fermier la tue. C'est un événement porteur d'une information infinie (pour la dinde) qui contredit 1000 jours d'observation. »

La dinde a confondu l'absence de bruit (basse entropie) avec l'absence de risque. Elle vivait dans un système à forte varentropie. La varentropie est la mesure de la trahison d'un système ou plus précisément la « volatilité » de la surprise. On retrouve cette idée en ingénierie quelques fois sous le nom de paradoxe de l'automatisation : un avion ancien faiblement automatisé produit une haute entropie mais une faible varentropie alors qu'un avion ultra-automatisé lisse tout, l'entropie perçue est basse, mais la varentropie augmente (si l'automatisme décroche brutalement, sortie du domaine de vol, la transition instantanée d'un état "tout va bien" à "décrochage complexe" génère un choc informationnel). La robustesse d'un système se « dimensionne » sur la varentropie et non sur l'entropie uniquement.

2 Principe de maximisation de l'entropie (MaxEnt)

Un principe que l'on retrouve souvent en théorie de l'information et en physique (statistique) est celui de la maximisation de l'entropie (souvent abrégé en MaxEnt). Ce principe dit en substance la chose suivante : **de toutes les distributions de probabilité cohérentes avec les faits que l'on connaît, il faut choisir celle d'entropie maximale.** La justification de ce principe peut être vu ainsi : si l'on décrit notre connaissance d'un système par la connaissance de sa distribution de probabilité, l'entropie (de Shannon) mesure en quelque sorte notre ignorance sur les états du système, au sens qu'elle mesure la quantité moyenne d'information qui nous manque pour connaître l'état du système. **Choisir la distribution qui maximise l'entropie c'est alors faire le choix de la distribution qui assume au maximum notre manque d'information sur le système.** En d'autre terme c'est la distribution qui introduit le moins d'hypothèses supplémentaires. Avec ce point de vu le principe de maximisation de l'entropie devient une règle logique, un principe de raisonnement « robuste » de non-engagement (et non un principe de vérité). D'un point de vue conceptuel le principe de maximisation de l'entropie est une version formelle du rasoir d'Ockham (version statistique).

1. Supposons que l'on sache que pour un i donné : $p_i = 1$ (i.e. que l'on connaisse exactement l'état de notre système). Que vaut l'entropie dans ce cas ?
2. Supposons que l'on ne suppose rien. Montrer que $H(p)$ est maximale pour une distribution uniforme.



Pause épistémologique : Il y a ici deux précautions/biais cognitifs à regarder. Le premier est l'**apophénie** : notre cerveau est une machine à détecter des motifs, à créer du sens (superstition, complotisme). Face à une série aléatoire (bruit pur), l'humain a tendance à "voir" des clusters, des cycles ou des tendances. Le calcul MaxEnt dans le cas précédent rappelle la position par défaut : sans contrainte explicite, la seule croyance rationnelle est l'uniformité. Ne pas faire le choix de l'uniforme dans ce cas génère une entropie plus faible et donc des biais structurels. Toute structure que vous imaginez est une hallucination statistique tant qu'elle n'est pas justifiée par une donnée. Le second, plus sournois, est celui que l'on qualifiera de **bias de l'uniforme naïf** consiste à appliquer l'uniformité même quand on a des contraintes, par paresse intellectuelle ou par excès de prudence. En pratique on voit que MaxEnt pour une ignorance totale est un état rare, nous avons presque toujours quelques informations à intégrer.

3. On suppose à présent connue la moyenne de la variable aléatoire i.e si l'on impose que :

$$E(X) = m \Leftrightarrow \sum_{i=1}^n x_i p_i = m$$

Montrer en utilisant la méthode des multiplicateurs de Lagrange (cf. Ma316) alors que la distribution qui maximise l'entropie pour une espérance donnée vérifie qu'il existe $\mu \in \mathbb{R}$ tel que :

$$p_i = \frac{e^{\mu x_i}}{\sum_{j=1}^n e^{\mu x_j}}$$

On appelle cette dernière distribution une **distribution de Boltzmann** (ou de **Gibbs**). On retrouve cette distribution en physique lorsque l'on cherche à calculer la probabilité qu'une particule soit dans l'état d'énergie $x_i = E_i$

sous la contrainte de connaître l'énergie totale $E = m$ du système. Le paramètre μ s'écrit alors dans ce cas :

$$\mu = -\frac{1}{k_B T}$$

où k_B est la constante de Boltzmann et T la température du système. Cette distribution est l'ingrédient de base pour montrer par exemple la loi des gaz parfaits. En supposant que les $0 \leq E_1 \leq E_2 \leq \dots \leq E_n$, on voit que les états les plus probables sont les états de plus faible énergie et ce phénomène est accentué si $|\mu|$ est grand (i.e. si T est petit). Ainsi en faisant tendre $\mu \rightarrow -\infty$ (i.e. $T \rightarrow 0$) on retrouve que tous les états du système sont dans l'état E_1 (si E_1 est l'unique état fondamental, les autres probabilités devant négligeables). on retrouve en version très simplifiée² une manière d'aborder classique l'état de Bose-Einstein. Inversement si $|\mu|$ est petit (i.e. T est grand) alors la probabilité d'être dans des états d'énergie élevée n'est plus négligeable. Dernière remarque, comme on ne peut prendre l'exponentielle que d'une quantité sans dimension il faut nécessairement que μ soit l'inverse d'une énergie et comme par des raisonnements (physiques) on peut montrer que μ est inversement proportionnel à la température (kelvin) alors il vient qu'il existe nécessairement une constante k_B en joules par kelvin. Question : que se passe-t-il lorsque $|T| \rightarrow +\infty$?

4. Supposons que les $0 \leq x_1 \leq x_2 \leq \dots \leq x_n$ et $\mu < 0$. En « dé » discrétisant l'intervalle $[0, +\infty[$ montrer que la version continue de la distribution de Boltzmann continue dont la densité s'écrit :

$$p(x) := \frac{e^{\mu x}}{\int_0^{+\infty} e^{\mu x} dx}$$

est une distribution de probabilité connue.



Pause épistémologique : Un biais courant est de mal estimer des événements rares sous une contrainte de « coût ». Les 2 questions précédentes montrent que lorsqu'une ressource est limitée (par exemple l'argent, l'énergie moyenne disponible, etc...) la distribution la plus naturelle n'est pas la "courbe en cloche" joliment symétrique de la loi normale. Le résultat trouvé ici fait apparaître une explication du pourquoi dans beaucoup de phénomènes sociaux (richesse) ou naturels, il y a beaucoup de "petits" et très peu de "gros" : c'est la configuration statistiquement la plus probable sous contrainte d'une moyenne fixe.

5. Revenons sur des probabilités finies. Supposons en plus des conditions de la question 2 i.e. une espérance fixée, une variance donnée :

$$\text{Var}(X) = \sigma^2 = \sum_{i=1}^n x_i^2 p_i - m^2$$

Montrer qu'il existe deux réels μ_1 et μ_2 tel que la distribution maximisant l'entropie pour une espérance et une variance donnée s'écrit :

$$p_i = \frac{e^{(\mu_1 x_i + \mu_2 x_i^2)}}{\sum_{j=1}^n e^{(\mu_1 x_j + \mu_2 x_j^2)}}$$

6. (Plus difficile) Comme à la question 3, supposons que $\mu_2 < 0$ et que $x \in]-\infty, +\infty[$ calculer sur le même modèle la distribution « dédiscretisée ». Quelle loi très classique reconnaît-on ? Ce résultat éclaire sur le fait que l'on retrouve cette loi très souvent un peu partout.

2.1 Pour les probabilités continues

Soit X une v.a. réelle admettant une densité f . Nous allons généraliser de manière « naturelle » la définition précédente de l'entropie de Shannon en posant :

$$H(X) := - \int_{\mathbb{R}} f(x) \ln(f(x)) dx$$

avec la convention que : $0 \ln(0) = 0$. On appelle cette forme « généralisée » de l'entropie : l'**entropie différentielle**. Nous allons voir que l'entropie différentielle possède des propriétés très différentes avec l'entropie discrète (pas toutes, certaines sont communes). Le passage du discret au continu ne se fait pas sans conséquence : dans les modèles continus pour avoir une information « sensée », il faut des contraintes (une borne physique ou une énergie finie/variance). Sans contraintes, la "liberté totale" est synonyme de "néant informationnel".

²Il faudrait faire de la mécanique quantique pour en dire plus. L'état de Bose-Einstein (le vrai) se manifestant pour une température finie, il conviendrait de prendre en compte les propriétés quantiques du système et donc cela revient à choisir une autre distribution de probabilité.

1. Justifier que l'entropie différentielle peut être négative. Comparer cela avec l'entropie discrète (entropie de Shannon). Justifier par le calcul l'affirmation suivante : l'entropie différentielle ne mesure pas l'information absolue, mais l'information relative au système de coordonnées.
2. Montrer que H est concave.
3. Montrer qu'il n'existe pas de distribution à densité qui maximise l'entropie différentielle. On pourra utiliser ce que l'on sait dans le cas discret.
4. Même question si l'on impose la valeur de l'espérance.
5. Montrer que parmi les v.a.r centrée-réduite, la distribution qui maximise l'entropie différentielle est la loi normale centrée-réduite $\mathcal{N}(0, 1)$.
6. Calculer l'entropie de $\mathcal{N}(0, 1)$.
7. Calculer l'entropie des lois suivantes : loi uniforme $\mathcal{U}([a, b])$, loi exponentielle $\mathcal{E}(\lambda)$ et pour les lois de Pareto $\mathcal{P}(x_0, \alpha)$. Analyser les différents résultats.
8. Ouverture : à l'image de la partie 1.2, définissez la varentropie différentielle. Montrer que contrairement à l'entropie différentielle, la varentropie est invariante par changement d'échelle. Que vaut la varentropie pour les lois précédentes ?

3 L'entropie relative : la divergence de Kullback-Leibler (KL).

Dans la section précédente, nous avons défini l'entropie comme mesure de notre ignorance moyenne face par rapport à une distribution p . Mais que se passe-t-il lorsque nos croyances sont inexactes ? Imaginons que nous attribuions à un phénomène la distribution q , alors que la réalité objective suit p . Nous allons voir que ce que l'on nomme la divergence KL quantifie précisément le "coût informationnel" de cette erreur de modélisation.

Supposons que l'on associe une distribution de probabilité (finie) q à un jeu complet d'événements, nous dirons que q est notre modèle. Or en réalité ce jeu complet d'événements suit une probabilité p . Ainsi si l'on regarde comme dans la section 1, la variable aléatoire mesurant l'information portée par cette « mauvaise » estimation q sous la probabilité p :

$$I_q(i) := \begin{cases} -\ln q_i & \text{si } q_i \neq 0 \\ 0 & \text{sinon} \end{cases}$$

L'espérance de cette variable aléatoire est si aucun $q_i = 0$:

$$E_p(I_q) = \sum_{i=1}^n -p_i \ln q_i$$

où l'on note E_p pour spécifier que l'on fait l'espérance sous la probabilité p . Si l'on interprète l'entropie (cf. section 1) :

$$H(p) = -\sum_{i=1}^n p_i \ln(p_i)$$

comme la mesure de notre ignorance résiduelle moyenne, la quantité $E_p(I_q)$ est notre ignorance résiduelle moyenne « biaisée » (par mon erreur de jugement qui me fait croire q à la place de p). On peut calculer l'écart entre ses deux quantités, afin de mesurer notre « erreur » de perception :

$$E_p(I_q) - H(p) = \sum_{i=1}^n -p_i \ln q_i - \left(-\sum_{i=1}^n p_i \ln(p_i) \right) = \sum_{i=1}^n p_i \ln \left(\frac{p_i}{q_i} \right)$$

Nous allons voir que cette quantité a une grande importance. Elle mesure le « coût informationnel » de cette erreur de modélisation ou la « surprise » moyenne que l'on a à voir se réaliser p alors que l'on pensait q .

Soient $p, q \in \Delta_n$. On appelle **entropie de q relative à p** ou **divergence Kullback-Leibler** (divergence KL pour les intimes) la quantité suivante :

$$KL(p \| q) := \sum_{i=1}^n p_i \ln \left(\frac{p_i}{q_i} \right)$$

avec les conventions $0 \ln(0/q_i) = 0$ et s'il existe i tel que : $p_i > 0$ et $q_i = 0$, alors on pose : $KL(p \| q) = +\infty$.

 **Pause épistémologique :** Le biais d'optimisme (ou biais de calibrage) quantifié. Regardons un petit exemple pour comprendre en quoi la divergence KL donne une mesure quantitative de la dissonance cognitive. La météorologie montre que sur une île tropicale la pluie représente 25% du temps pour 75% de soleil i.e. $p := (p_{\text{pluie}} = 0,25; p_{\text{soleil}} = 0,75)$ est la réalité « terrain ». Influencé par des brochures publicitaires, un touriste arrive convaincu qu'il fait presque toujours beau i.e. dans son esprit il pense que : $q := (q_{\text{pluie}} = 0,01; q_{\text{soleil}} = 0,99)$. Alors :

$$KL(p||q) \simeq 0,61$$

est la mesure de la surprise moyenne du touriste dû à son image erronée de la météo réelle de cette île. D'un point de vue informationnel c'est le coût « informationnel » moyen du biais du touriste. En d'autres termes cela mesure le coût moyen pour le touriste de « mettre » à jour sa croyance initiale erronée.

1. Commençons par montrer les propriétés suivantes (on pourra utiliser la concavité du logarithme...) :
 - a) Pour tout $p, q \in \Delta_n$, $KL(p||q) \geq 0$.
 - b) De plus : $H(p|q) = 0 \Leftrightarrow p = q$.
 - c) $H(p|q) < \infty \Leftrightarrow \text{supp}(p) \subset \text{supp}(q)$.
 - d) Soit $p \in \Delta_n$ fixé. La fonction $q \mapsto KL(p||q)$ est convexe.
2. Calculer l'entropie de $H(u_n)$ où u_n est la loi uniforme (discrète). En déduire une expression de $KL(p||u_n)$ et $KL(u_n||p)$ en fonction de $H(u_n)$.
3. Montrer que la divergence KL ne peut pas être une distance (au sens mathématiques). En particulier on vérifiera qu'elle n'est pas symétrique et qu'elle ne vérifie pas l'inégalité triangulaire.
4. En utilisant les lois usuelles de probabilités discrètes finies, calculer $KL(p||q)$ (et son « symétrique ») pour différentes paires de distributions. On testera des distributions d'entropies différentes entre elles. Par exemple calculer $KL(p||u_n)$ et $KL(u_n||p)$ pour une loi $p := (\lambda, 1 - \lambda)$ de Bernoulli en faisant varier λ . On tracera les résultats obtenus.

 **Pause épistémologique :** La loi de Brandolini ou principe d'asymétrie du baratin (*Bullshit Asymmetry Principle*). Cette loi a été formulée par le programmeur italien Alberto Brandolini en 2013 à propos des contre-vérités de certains hommes politiques sous la forme suivante : « La quantité d'énergie nécessaire pour réfuter du baratin (bullshit) est supérieure d'un ordre de grandeur à celle nécessaire pour le produire ». L'asymétrie de la divergence KL n'est pas une curiosité algébrique c'est une illustration formelle que le coût pour désapprendre une erreur (passer de la croyance fausse q à la vérité p) n'est pas le même que le coût pour tomber dans l'erreur (passer de la vérité p à l'erreur q). La question précédente montre même une nuance importante. A supposer que le mouvement naturel de l'esprit va naturellement vers une surprise moindre (une thermodynamique cognitive ?) i.e. recherche une valeur de la divergence KL basse lors d'un déplacement entre deux opinions, il vient qu'il est plus coûteux de faire passer d'une croyance dogmatique (une distribution q avec une faible entropie) à une croyance nuancée (une distribution p avec une entropie élevée), $KL(p||q)$ que l'inverse $KL(q||p)$ i.e. passer d'une vérité « claire » (faible entropie) à une vision « molle »/nuancée.

5. Lien entre le maximum de vraisemblance et la minimisation de la divergence KL. Soit $x := (x_1, \dots, x_n)$ une réalisation d'un n -échantillon $(X_1, \dots, X_n)$ de loi parente X une v.a finie de loi inconnue p à support $\Omega := \{1, \dots, n\}$. On rappelle (cf. cours) la définition de la **distribution empirique associée à cette réalisation x** :

$$\hat{p}(i) := \frac{1}{n} \sum_{k=1}^n 1_{\{X_k=i\}}$$

avec $1_{\{X_k=i\}} = 1$ si $x_k = i$ et 0 sinon (c'est l'indicatrice discrète). Soit q_θ une famille de distribution de probabilité de taille n dépendant d'un paramètre $\theta \in \mathbb{R}$ i.e. que q_θ est une notation pour le vecteur de taille de composante $i : q_\theta(i) = P_\theta(X = i)$. On supposera que $q_\theta(i) > 0$ dès que $\hat{p}(i) > 0$, pour tout $i \in \llbracket 1, n \rrbracket$.

- a) Rappeler l'expression de la fonction de vraisemblance (discrète) associée à $x : L_x(\theta)$ en $\theta \in \mathbb{R}$. Rappeler pourquoi la recherche du maximum de vraisemblance (MLE) θ_{MLE} revient à :

$$\theta_{MLE} \in \arg \max_{\theta} l_x(\theta)$$

où l_x est la log-vraisemblance.

- b) Montrer alors l'équivalence :

$$\theta_{MLE} \in \arg \max_{\theta} l_x(\theta) \Leftrightarrow \theta_{MLE} \in \arg \min_{\theta} KL(\hat{p}||q_\theta)$$

Ainsi trouver la distribution qui maximise la vraisemblance des données observées revient à chercher la distribution qui minimise la « surprise » informationnelle produite par les données observées.

6. Dans l'exercice 10 du TD1, nous avons comparé des jeux de données réelles avec la loi de Newcomb-Benford (d'ordre 1) définie par :

$$b_i := \log \left(1 + \frac{1}{i} \right)$$

pour $i \in \llbracket 1, 9 \rrbracket$. Pour mesurer l'écart d'un histogramme p construit avec des données réels et b (la loi de Newcomb-Benford) nous avons utilisé la norme euclidienne (`np.linalg.norm` dans Python). Justifier que l'on a une comparaison bien plus fine si l'on utilise la divergence KL :

$$KL(b \| p) \text{ ou } KL(p \| b)$$

Expliquer la différence de choix entre ces deux divergences KL. Montrer que des écarts faibles sur les fréquences du 1 par rapport à b_1 , par exemple $p_1 = b_1 + 0,02$, n'ont pas le même poids informationnel que d'avoir ces mêmes écarts sur les fréquences du 9 alors que ces mêmes écarts ne sont quasiment pas différenciés par la métrique euclidienne.

4 Explorer la géométrie des distributions de probabilités (finies)

Dans la sous-section précédente nous avons vu que la divergence KL, par exemple $KL(p \| q)$, mesure en quelque sorte la surprise de constater qu'un système suit une loi p alors que l'on croyait qu'il suivait une loi q . Cette mesure va nous permettre de décrire formellement un « bon » processus d'apprentissage. Commençons par une définition générale : nous dirons qu'un **processus d'apprentissage** d'un système qui suit une loi p (la vérité du modèle) c'est la donnée d'une fonction différentiable :

$$p : [0, 1] \rightarrow \dot{\Delta}_n$$

où $p(0)$ est l'état initial de notre connaissance sur les n -états possibles du système considérées et $p(1)$ est l'état « réel » de ce système. On se place $\dot{\Delta}_n$ et non dans Δ_n afin de suivre la règle de Cromwell (cf. encadrée section précédente). Ainsi apprendre est un chemin dans l'espace $\dot{\Delta}_n$ qui relie notre croyance initiale à l'état réel du système. Or ce que nous voulons n'est pas seulement d'apprendre mais d'apprendre efficacement. C'est ici que les formalisations des parties précédentes vont nous permettre de définir ce que signifie apprendre efficacement. Il nous faut donc décrire la géométrie des processus d'apprentissages i.e comment cartographier les reliefs que doit suivre la pensée. Alors, lorsqu'on veut connaître un lieu inconnu, on s'y promène i.e. mathématiquement nous allons nous placer dans la peau d'un explorateur géomètre en nous « promenant » dans $\dot{\Delta}_n$. Mathématiquement se promener c'est donc considérer une fonction différentiable :

$$p : [0, 1] \rightarrow \dot{\Delta}_n$$

dans un lieu où le relief local est contraint par la surprise informationnelle (divergence KL) de passer d'une croyance $p(t)$ à une croyance $p(t + \epsilon)$. Comme dans une randonnée classique : tous les chemins imaginables ne sont pas possibles ainsi quelles sont les « promenades » possibles ? En particulier quelles sont les « vitesses » possibles ? Voyons l'expression formelle de ces contraintes. Comme pour une distribution de probabilité on a la contrainte :

$$\sum_{i=1}^n p_i(t) = 1$$

il vient que le vecteur vitesse $\dot{p}(t)$ en $t \in [0, 1]$ doit vérifier :

$$\sum_{i=1}^n \dot{p}_i(t) = 0$$

Ainsi la première contrainte à laquelle nous sommes soumis et que l'espace des vitesses admissibles en chaque point $p(t)$ est le sous-espace de $\mathbb{R}^n$:

$$\left\{ x \in \mathbb{R}^n \mid 1_n^T x = \sum_{i=1}^n \dot{p}_i(t) = 0 \right\}$$

On appelle cet espace l'espace tangent en $p(t)$ et on le note :

$$T_{p(t)} \dot{\Delta}_n$$

pour préciser en quel point $p(t)$ nous nous trouvons.

4.1 Promenons-nous dans $\mathring{\Delta}_n \dots$

Formalisons le déplacement local entre deux points de notre espace avec comme le relief donnée par la divergence KL. Soient $p, q \in \mathring{\Delta}_n$ et fixons $0 \leq t \leq 1$, notons :

$$p(t) := (1-t)p + tq = p + t(q-p) \in \mathring{\Delta}_n$$

un chemin « simple » de p à q . Avec ces notations $p(0) = p$. Notons pour alléger les formules suivantes :

$$h := q - p$$

De cette façon on peut voir h comme $h \in T_p \mathring{\Delta}_n$, c'est la direction du déplacement. Que devient la divergence KL proche de p i.e. quelle est l'influence du relief informationnel localement ?

1. Commençons par un petit lemme : soit x, y deux réels et $\epsilon > 0$ un réel « petit » tel que la quantité :

$$f(\epsilon) := (x + \epsilon y) \ln \left(\frac{x + \epsilon y}{x} \right)$$

est bien définie. Montrer qu'à l'ordre 2 on a :

$$f(\epsilon) = \epsilon y + \epsilon^2 \frac{y^2}{2x} + o(\epsilon^2)$$

2. En déduire qu'à l'ordre 2 on a :

$$KL(p(\epsilon) \| p) = \frac{\epsilon^2}{2} \sum_{i=1}^n \frac{h_i^2}{p_i} + o(\epsilon^2) \quad \text{et} \quad KL(p \| p(\epsilon)) = \frac{\epsilon^2}{2} \sum_{i=1}^n \frac{h_i^2}{p_i} + o(\epsilon^2)$$

Ainsi à l'ordre 2 la divergence KL est symétrique et la géométrie est donnée localement près d'un point p par la forme quadratique précédente (on ne prend pas la constante $\frac{1}{2}$ pour coller à la littérature classique sur le sujet). Plus généralement on posera :

$$g_p(u, v) := u^T \begin{pmatrix} \frac{1}{p_1} & & \\ & \ddots & \\ & & \frac{1}{p_n} \end{pmatrix} v = \sum_{i=1}^n \frac{u_i v_i}{p_i}$$

avec $u, v \in T_p \mathring{\Delta}_n$. On appelle g_p la **métrique de Fisher-Rao** en p .

 **Pause épistémologique : Le coût de changer ses croyances.** La géométrie des croyances n'est donc pas euclidienne (ce que nous avons déjà vu) mais nous pouvons maintenant en dire plus. En géométrie euclidienne un petit déplacement ds^2 (le carré d'un déplacement) est donnée par (théorème de Pythagore) :

$$ds^2 = \sum_{i=1}^n dp_i^2$$

Le calcul précédent montre qu'un petit déplacement dépend du lieu où on se trouve, ici une croyance p , et est donnée par :

$$dp^2 = \sum_{i=1}^n \frac{dp_i^2}{p_i}$$

Ainsi si je crois qu'un évènement A_i est probable à 1%, notons $p_i = 0,01$ alors modifier ma croyance sur cet évènement produit une plus grande « révolution » dans mes croyances donnée (sur la composante i) par : $\frac{dp_i^2}{p_i} = 100dp_i^2$, que modifier mes croyances sur un évènement B_j que je jugeais fortement probable, par exemple $p_j = 0,9$:

$$\frac{dp_j^2}{p_j} = \frac{100}{90}dp_j^2$$

On voit que toutes nos opinions ne se valent pas, la métrique n'est pas euclidienne en général. Elle est euclidienne si et seulement pour l'opinion/croyance la moins « tranchée » possible i.e pour la distribution uniforme u_n . Dans ce cas on a bien la métrique euclidienne à une constante près multiplicative :

$$dp^2 = \sum_{i=1}^n \frac{dp_i^2}{\left(\frac{1}{n}\right)} = nds^2$$

Au passage, on remarque que la finesse de ce langage permet même de voir que la constante multiplicative étant n , la dimension (= les différents états possibles), on voit que plus le système possède d'état plus les déplacements de nos croyances à partir de l'uniforme sont grands. Pour le dire autrement : être indifférent à tous les états possibles demande un plus grand engagement « moral » à mesure que n augmente. Le choix de la parfaite indifférence (loi uniforme) à un monde très complexe (n grand) est donc en réalité une position très instable (le moindre écart donne de grandes valeurs) et le coût du déplacement vers une certitude à partir de ce point de vue est fortement augmenté (cela demande une forte accumulation de « preuve »).

3. Nous avons à présent le moyen de définir le « relief » localement par la métrique de Fisher-Rao précédente. Considérons un chemin différentiable :

$$\gamma : [0, 1] \rightarrow \mathring{\Delta}_n$$

tel que : $\gamma(0) = p$ et $\gamma(1) = q$ pour $p, q \in \mathring{\Delta}_n$. On supposera que γ est différentiable. Le calcul différentiel nous dit que la longueur du chemin γ est la somme des déplacements infinitésimaux i.e avec la métrique de Fisher-Rao :

$$l(\gamma) := \int_0^1 \sqrt{g_{\gamma(t)}(\dot{\gamma}(t), \dot{\gamma}(t))} dt = \int_0^1 \sqrt{\sum_{i=1}^n \frac{\dot{\gamma}(t)_i^2}{\gamma(t)_i}} dt$$

On appelle **distance géodésique** la longueur du plus (ou des) court chemin entre deux points i.e la distance géodésique entre les distributions p et q est définie par :

$$d(p, q) := \inf_{\gamma, \gamma(0)=p, \gamma(1)=q} l(\gamma)$$

Nous allons calculer dans cette question cette distance i.e la distance géométrique entre deux états de croyances. Les courbes réalisant cette plus courte distance sont appelés les **géodésiques** (les lignes droites en géométrie euclidienne par exemple).

- a) Posons le changement de variable :

$$\phi(t)_i := \sqrt{\gamma(t)_i} \forall i \in \llbracket 1, n \rrbracket$$

Montrer que :

$$l(\gamma) = 2 \int_0^1 \|\dot{\phi}(t)\|_2 dt$$

- b) En déduire que la recherche des géodésiques pour la géométrie de Fisher-Rao revient à rechercher les plus courts chemins sur l'orthant positif de la sphère unité S^{n-1} i.e à résoudre le problème d'optimisation sous contrainte suivant :

$$(\mathcal{G}) : \begin{cases} \arg \min_{\phi} \int_0^1 \|\dot{\phi}(t)\|_2^2 dt \\ \text{sous les contraintes : } \|\phi(t)\|_2^2 = 1, \forall t \in [0, 1] \quad \phi(0) = \sqrt{p}, \phi(1) = \sqrt{q} \end{cases}$$

où $\sqrt{p} := (\sqrt{p_1}, \dots, \sqrt{p_n}) \in \mathring{\Delta}_n$. On peut résoudre alors le problème $(\mathcal{G})$ en utilisant la méthode des multiplicateurs de Lagrange (cf. Ma316) sur l'intégrale d'action suivante :

$$\mathcal{A}(\phi) := \int_0^1 \left(\|\dot{\phi}(t)\|_2^2 + \lambda(t) \left(\|\phi(t)\|_2^2 - 1 \right) \right) dt$$

avec $\lambda(t) \in \mathbb{R}$. Montrer que les équations d'Euler-Lagrange conduisent aux systèmes harmoniques suivant :

$$\begin{cases} \ddot{\phi}_i(t) + \|\dot{\phi}(t)\|_2^2 \phi_i(t) = 0 & \forall t \in [0, 1], \forall i \in \llbracket 1, n \rrbracket \\ \|\phi(t)\|_2^2 = 1, & \phi(0) = \sqrt{p}, \phi(1) = \sqrt{q} \end{cases}$$

- c) Comme cela ne change pas la longueur de la courbe de la parcourir en faisant varier sa vitesse, nous allons chercher les solutions à vitesse constante (la norme constante) i.e. telles que pour tout $t \in [0, 1]$:

$$\|\dot{\phi}(t)\|_2^2 = \theta^2$$

pour $\theta \in \mathbb{R}$. Sous ces conditions montrer que les géodésiques s'écrivent explicitement sous la forme suivante pour chacune des composantes (attention de bien utiliser toutes les contraintes et la trigonométrie...) :

$$\gamma(t)_i := \left(\frac{\sqrt{p_i} \sin(\theta(1-t)) + \sqrt{q_i} \sin(\theta t)}{\sin(\theta)} \right)^2$$

avec :

$$\theta = \arccos \left(\sum_{i=1}^n \sqrt{p_i q_i} \right)$$

et que la distance est :

$$d(p, q) = 2\theta = 2 \arccos \left(\sum_{i=1}^n \sqrt{p_i q_i} \right)$$

On voit que la définition de la distance que nous avons trouvée s'étend au cas des distributions p et q ne vérifiant pas la règle de Cromwell i.e. possédant des supports non pleins. La formule garde un sens mathématique même pour des p_i et q_i nuls.



Pause épistémologique : Le lion de Wittgenstein. Dans l'ouvrage posthume, *Investigations philosophiques*, le philosophe Wittgenstein donne l'affirmation suivante : « Si un lion pouvait parler, nous ne pourrions pas le comprendre. » Non pas à cause de la grammaire, mais parce que ne nous partagerions pas du tout les mêmes représentations mentales et expériences vécues (Wittgenstein parle de « forme de vie »). Prenons deux personnes aux opinions/croyances formalisées par p et q respectivement. La distance $d(p, q)$ est maximale si l'arc cosinus est évalué en 0 (car $p_i, q_i \geq 0$) i.e si les vecteurs « croyances » p et q sont orthogonaux. Dans ce cas les supports de p et q sont complètement disjoints, ce que pense A comme possible est considéré comme impossible par B. Ce n'est plus un simple désaccord sur des probabilités, c'est un désaccord sur le répertoire des possibles. Néanmoins par rapport à ce que nous dit Wittgenstein : la distance maximale n'est pas « infinie », elle est finie (elle vaut π), il y a donc toujours un espoir !

Au delà de cela, on voit que cette distance et les calculs précédents permettent de distinguer deux types de désaccords :

- le désaccord « quantitatif » ($\sum_{i=1}^n \sqrt{p_i q_i} = \epsilon$ petit) : p et q ont même support mais les valeurs individuelles des croyances p_i et q_i sont différentes. Si n est grand la distance peut tendre vers π . Les individus possèdent les mêmes « possibles » et on peut espérer converger par l'accumulation de données et preuves.
- le désaccord « ontologique » ($\sum_{i=1}^n \sqrt{p_i q_i} = 0$) : p et q n'ont pas le même support et dans ce cas les deux individus doivent d'abord s'efforcer de construire une sorte de « socle commun » i.e se mettre d'accord sur ce qui est autorisée comme explication ou non. Sans cela toute stratégie d'apprentissage est inefficace (le support restera disjoint et donc la distance maximale).

4. **La moyenne de Fréchet ou comment corriger le sophisme du juste milieu.** Supposons que nous ayons un comité de K experts, chacun fournissant une distribution de probabilité $p^{(k)} \in \mathring{\Delta}_n$ sur un même phénomène. Nous cherchons à synthétiser ces opinions en une seule distribution représentative $\bar{p}$ sans tomber dans le piège du sophisme du juste milieu (cf. encadré Pause épistémologique). Le « juste milieu » correspond à prendre la moyenne arithmétique i.e :

$$p^{(m)} := \frac{1}{K} \sum_{k=1}^K p^{(k)}$$

Cette moyenne ne prend pas en compte la géométrie. On définit alors la moyenne de Fréchet (=le barycentre géométrique) par :

$$p^* := \arg \min_{p \in \hat{\Delta}_n} \sum_{k=1}^K d(p, p^{(k)})$$

On ne traitera ici en exemple que le cas $K = 2$. Notons $p^{(1)}$ et $p^{(2)}$ les prédictions de nos deux experts.

- a) Montrer que p^* est le milieu de la géodésique γ reliant $p^{(1)}$ à $p^{(2)}$ i.e. $p^* := \gamma\left(\frac{1}{2}\right)$.
- b) Application 1 : Supposons que deux experts A et B sont consultés sur un problème à deux issues ($n = 2$).
 - L'expert A donne la prédiction de $p^{(1)} = (0, 4; 0, 6)$.
 - L'expert B donne la prédiction de $p^{(2)} = (0, 01; 0, 99)$.

Calculer la moyenne arithmétique puis la moyenne de Fréchet. Comparer l'entropie respective de ces deux moyennes. Pourquoi peut-on dire que le consensus utilisant la moyenne de Fréchet est moins « flou » sur le plan informatif ?

- c) Application 2 : Sous Python, en considérant des images (en niveau de gris pour commencer puis en couleurs) comme des distributions de probabilités (il suffit de diviser par la somme totale des coefficients de la matrice), montrer que la moyenne de Fréchet deux images donne des résultats plus « propre » que la simple moyenne arithmétique. Comparer l'entropie respective de ces deux moyennes.

5 Applications aux promenades géodésiques

Dans cette section nous allons voir des conséquences des formules précédentes.

5.1 La loi de Bernoulli et l'estimation géométrique

Supposons un système à deux états possibles ($n = 2$, un sondage entre deux options A et B par exemple) avec $\Omega = \{0, 1\}$ dont le comportement suit une loi de Bernoulli de paramètre $\lambda > 0$ dont on cherche à estimer la valeur. Supposons que l'on se donne un n -échantillon $(X_1, \dots, X_n)$ de loi $\mathcal{B}(\lambda)$.

1. Rappeler pourquoi l'estimateur de la moyenne empirique $\bar{X}_n$ est un estimateur sans biais de λ . Donner le risque quadratique de cet estimateur que peut-on dire de la convergence de cet estimateur ?
2. Le problème de l'estimateur précédent est que son risque quadratique dépend de la valeur réelle de λ (nous avons fait une majoration « brute » en TD de $\lambda(1 - \lambda)$ par $\frac{1}{4}$). Pourquoi cette dépendance peut être problématique ?
3. Voyons ce que nous dit la géométrie que l'on a produit. Notons :

$$p := (\lambda, 1 - \lambda)$$

la distribution de probabilité « réelle » du système. Regardons ce que donne un petit déplacement en le point p :

$$dp := (d\lambda, -d\lambda) \in T_p \hat{\Delta}_2$$

Calculer :

$$dl^2 := g_p(dp, dp)$$

en déduire que l'on pose comme élément de longueur infinitésimal :

$$dl = \frac{1}{\sqrt{\lambda(1 - \lambda)}} d\lambda$$

Cette relation va nous permettre de penser λ comme la valeur d'une variable aléatoire réelle.

4. Regardons Λ la variable aléatoire réelle donnant la valeur de $\lambda \in [0, 1]$. Déterminer α tel que :

$$f_\Lambda(\lambda) = \alpha \frac{1}{\sqrt{\lambda(1 - \lambda)}} \chi_{[0,1]}(\lambda)$$

soit une densité de probabilité. Calculer sa fonction de répartition, son espérance ainsi que sa variance. On appelle cette loi la loi arcsinus.

5. Supposons que l'on possède une n -réalisation $x := (x_1, \dots, x_n)$ du n -échantillon $(X_1, \dots, X_n)$. Montrer que la fonction de vraisemblance est donnée par :

$$L_x(\lambda) = \lambda^k (1 - \lambda)^{n-k} \chi_{[0,1]}(\lambda)$$

avec $k := \sum_{i=1}^n 1_{\{x_i=1\}}$ (c'est le nombre de succès observés). On s'intéresse alors à la densité de probabilité :

$$f_{\Lambda|x}(\lambda) := \frac{1}{\int_0^1 L_x(\lambda) f_{\Lambda}(\lambda) d\lambda} L_x(\lambda) f_{\Lambda}(\lambda)$$

qui représente la densité de la loi du paramètre λ vu comme une v.a.r Λ sous la réalisation x . On appelle $\Lambda|x$ la **loi de Λ conditionnelle par rapport à x** .

6. Montrer que $\Lambda|x$ suit une loi bêta $Beta\left(k + \frac{1}{2}, n - k + \frac{1}{2}\right)$. En utilisant les résultats connus (ce n'est pas la peine de refaire les calculs) sur les lois Beta démontrer que :

$$E(\Lambda|x) = \frac{k + \frac{1}{2}}{n + 1}$$

C'est la valeur moyenne de Λ sous l'observation x .

7. On prendra alors l'**estimateur géométrique** :

$$\hat{\Lambda} := \frac{\sum_{i=1}^n X_i + \frac{1}{2}}{n + 1}$$

Rappeler quelle loi très connue suit $S_n := \sum_{i=1}^n X_i$. Calculer le biais de cet estimateur. Montrer que cet estimateur est biaisé mais asymptotiquement sans biais (on dit qu'il est consistant) sauf pour une valeur de λ où il est sans biais. puis montrer son risque quadratique (MSE) est donnée par :

$$r(\hat{\Lambda}) := \frac{1}{(n+1)^2} \left((n-1)\lambda(1-\lambda) + \frac{1}{4} \right)$$

8. Supposons que la valeur réelle est $\lambda^* = 0,01$. Sur 10 réalisations de l'expérience ($n = 10$) on trouve 10 échecs. Comparer les prédictions de $\hat{\Lambda}$ et $\bar{X}_n$.
9. Réaliser des simulations sous Python pour différentes valeurs de λ et de n et comparer les résultats obtenus par les estimateurs précédents (on regardera tout particulièrement les valeurs de λ extrêmes et proche de $\frac{1}{2}$).

L'estimateur issu de la géométrie accepte d'introduire un léger biais (qui s'annule à l'infini) pour « gagner » en prudence. L'estimateur géométrique évite mieux des erreurs de jugement qui pourrait être catastrophiques.

5.2 Géodésique et dérivée covariante : le gradient naturel

Cette partie utilisera de manière essentielle les notions développées en 4.1. Supposons que l'on souhaite résoudre un problème de la forme :

$$\arg \min_{p \in \hat{\Delta}_n} J(p)$$

avec J une fonction différentiable à valeurs réelles. Comme $p \in \hat{\Delta}_n$ c'est un problème d'optimisation sous-conainte. On a vu la « lenteur » des algorithmes classiques du style du gradient projeté, par exemple en Ma326 dans $\mathbb{R}^n$ pour la résolution des problèmes de ce genre. Nous allons utiliser la structure géométrique définie précédemment afin de produire un algorithme performant. Dans $\mathbb{R}^n$, i.e. dans l'espace euclidien, le développement de Taylor de J en p dans une direction v est donnée par :

$$J(p + \epsilon v) = J(p) + \epsilon v^T \nabla J(p) + o(\epsilon)$$

fait apparaître la différentielle : $d_p J(v) := v^T \nabla J(p)$ où $\nabla J(p)$ est le gradient de J en p . La différentielle est donc le produit scalaire euclidien de la direction v et du gradient. Or nous avons vu que la géométrie de « l'espace des croyances » $\hat{\Delta}_n$ n'est pas plate, elle est donnée par la **métrique de Fisher-Rao** g_p en p . Cette métrique dépend du

point p . Nous allons introduire ici la notion de gradient qui prend en compte la géométrie de $\mathring{\Delta}_n$. Pour cela il suffit de remplacer le produit scalaire euclidien par g_p .

On appelle **gradient naturel**, noté $\nabla^N J(p) \in T_p \mathring{\Delta}_n$ est un vecteur (dans l'espace tangent) tel que pour tout $v \in T_p \mathring{\Delta}_n$:

$$\sum_{i=1}^n \frac{\partial J}{\partial p_i} v_i = g_p(\nabla^N J(p)_i, v)$$

1. Montrer que la définition précédente implique que pour tout $i \in \llbracket 1, n \rrbracket$:

$$\frac{\partial J}{\partial p_i} = \frac{\nabla^N J(p)_i}{p_i} + \lambda$$

avec λ une constante réelle.

2. En utilisant le fait que (par définition) : $\sum_{k=1}^n w_k = 0$, en déduire que :

$$\lambda = \sum_{k=1}^n p_k \frac{\partial J}{\partial p_k}$$

et par suite :

$$\nabla^N J(p)_i = p_i \left(\frac{\partial J}{\partial p_i}(p) - \sum_{k=1}^n p_k \frac{\partial J}{\partial p_k}(p) \right)$$

3. Sous Python modifier l'algorithme de descente du gradient à pas fixe, en remplaçant le gradient par le gradient naturel $\nabla^N J(p)$. A chaque itération on normalisera numériquement le terme

$$p_n - \eta \nabla^N J(p_n)$$

pour qu'il reste dans $\mathring{\Delta}_n$. On appelle cet algorithme : la descente de gradient naturel. Bonus : on pourra utiliser la formule explicite des géodésiques (et même prendre la formule sur la sphère) pour mettre à jour la suite des points (p_n) (condition d'Armijo adaptée).



Pause épistémologique : Mise à jour des connaissances robustes. La mise à jour de nos connaissances par l'algorithme de descente de gradient naturel est une application du principe de précaution formulé par le physicien Carl Sagan sous la forme suivante : « Des affirmations extraordinaires nécessitent des preuves extraordinaires ». En effet la mise à jour de la composante i est proportionnelle à p_i . Ainsi la mise à jour d'un évènement marginal (p_i faible) sera marginale sauf si son écart à la moyenne :

$$\sum_{k=1}^n p_k \frac{\partial J}{\partial p_k}(p) = E_p(\nabla J(p))$$

est important et durable (se poursuit sur plusieurs itérations). Inversement le même phénomène donne naissance au fameux **biais de confirmation** : nous intégrons facilement les données qui renforcent nos croyances fortes (p_i grand). C'est cette même robustesse qui génère des paradoxes comme celui du « **moins mal** ». Prenons l'exemple simple d'une élection avec 3 candidats A, B, C. Les probabilités actuelles (sondages) sont :

$$p(t_0) := (0, 4; 0, 4; 0, 2)$$

Un scandale éclate et touche toute la classe politique. La fonction de satisfaction J s'effondre pour tout le monde. Les gradients euclidiens (variation de satisfaction) sont tous négatifs, par exemple :

- A : -10 (public déçu),
- B : -20 (public très déçu),
- C : -20 (public très déçu).

L'intuition euclidienne (l'esprit naïf) verrait le score de tous les candidats baisser, par exemple A devrait voir sa probabilité baisser (c'est ce que donne le gradient euclidien). Or si l'on calcule le gradient naturel pour A on trouve :

$$\nabla J(p(t_0))_1 = 0,4 \times (-10 - (-16)) = +2,4$$

Ainsi $\nabla J(p(t_0))_1 > 0$, les intentions de vote pour A vont au contraire augmenter (le calcul complet donne -1,6 pour B et -0,8 pour C).

5.3 Transport parallèle

Cette partie reprend les notions de la section 4. Soit une v.a. discrète finie de taille n , x de probabilité p i.e : $P(X = x_i) = p_i$. On supposera que le vecteur x est centré i.e :

$$\sum_{i=1}^n x_i = 0$$

On peut donc voir x comme un vecteur tangent en p i.e $x \in T_p \hat{\Delta}_n$. La question est : comment transporter les valeurs de x en une v.a discrète de probabilité q ? Par exemple si x représente les choix stratégiques d'une entreprise (=valeurs d'investissement) en fonction de l'état d'un marché (= la distribution p), comment adapter la stratégie si l'état du marché passe de p à une distribution $q \in \hat{\Delta}_n$? Nous allons voir que c'est l'importante notion en géométrie de transport parallèle qui permet de réaliser cela.

On a vu comment dans la section 4 s'expriment les géodésiques de p à q (la distribution de probabilité cible) tout $t \in [0, 1]$:

$$\gamma_i(t) := \left(\frac{\sqrt{p_i} \sin(\theta(1-t)) + \sqrt{q_i} \sin(\theta t)}{\sin(\theta)} \right)^2$$

pour $i \in \llbracket 1, n \rrbracket$ avec :

$$\theta := \frac{d(p, q)}{2} = \arccos \left(\sum_{i=1}^n \sqrt{p_i q_i} \right)$$

On définit le **transport parallèle de x le long de γ** par la donnée d'une courbe :

$$v : [0, 1] \rightarrow T^n := \left\{ x \in \mathbb{R}^n \mid 1_n^T x = \sum_{i=1}^n \dot{p}_i(t) = 0 \right\}$$

telle que :

- $v(0) = x$
- la norme géométrique : $\|v(t)\|_{g_{\gamma(t)}}^2 := g_{\gamma(t)}(v(t), v(t))$ est constante i.e :

$$\frac{d}{dt} \left(\|v(t)\|_{g_{\gamma(t)}}^2 \right) = 0$$

pour tout $t \in [0, 1]$.

1. Montrer que le vecteur :

$$\frac{Dv}{dt}(t) := \dot{v}_i(t) - \frac{1}{2} \frac{\dot{\gamma}_i(t)}{\gamma_i(t)} v_i(t) + \frac{1}{2} \gamma_i(t) \sum_{k=1}^n \left(\frac{\dot{\gamma}_k(t)}{\gamma_k(t)} v_k(t) \right)$$

est le vecteur qui vérifie pour tout $t \in [0, 1]$:

$$\frac{d}{dt} \left(\|v(t)\|_{g_{\gamma(t)}}^2 \right) = 2g_{\gamma(t)} \left(\frac{Dv}{dt}(t), v(t) \right)$$

On appelle ce vecteur la **dérivée covariante de v le long de la courbe γ** .

2. Pour définir le transport parallèle, il faut donc résoudre :

$$\frac{Dv}{dt}(t) = 0 \Leftrightarrow \dot{v}_i(t) = \frac{1}{2} \frac{\dot{\gamma}_i(t)}{\gamma_i(t)} v_i(t) - \frac{1}{2} \gamma_i(t) \sum_{k=1}^n \left(\frac{\dot{\gamma}_k(t)}{\gamma_k(t)} v_k(t) \right) \quad \forall i \in \llbracket 1, n \rrbracket \quad (\star)$$

Nous allons voir que l'on peut trouver une formule exacte à ce problème (mais il va falloir un peu de travail avant...). On pose les changements de variables (on revient sur la sphère) suivant :

$$\psi_i(t) := \sqrt{\gamma_i(t)} \quad \xi_i(t) := \frac{v_i(t)}{\psi_i(t)}$$

a) Démontrer la relation suivante pour tout t :

$$\dot{\xi}_i(t) = -\psi_i(t) \sum_{k=1}^n (\dot{\psi}_k(t) \xi_k(t)) = -\psi_i(t) \langle \dot{\psi}(t), \xi(t) \rangle$$

où $\langle \cdot, \cdot \rangle$ est le produit scalaire euclidien.

b) En utilisant l'expression explicite des géodésiques montrer que ψ vérifie l'équation différentielle suivante :

$$\ddot{\psi}_i(t) = -\theta^2 \psi_i(t)$$

c) Montrer que :

$$\frac{d}{dt} \langle \xi(t), \dot{\psi}(t) \rangle = 0$$

Ainsi :

$$\langle \xi, \dot{\psi} \rangle = \langle \xi(0), \dot{\psi}(0) \rangle := K$$

pour K une constante.

d) Démontrer alors que l'équation différentielle :

$$\dot{\xi} = -K\psi$$

implique que :

$$\xi(1) - \xi(0) = \frac{K}{\theta^2} (\dot{\psi}(1) - \dot{\psi}(0))$$

e) En remplaçant les changements de variables d'origines montrer que l'on a finalement l'expression du vecteur transporté en $t = 1$ donnée par :

$$v_i(1) = \sqrt{\frac{q_i}{p_i}} x_i - \frac{1}{1 + \cos(\theta)} \left(\sum_{k=1}^n x_k \sqrt{\frac{q_k}{p_k}} \right) (\sqrt{p_i q_i} + q_i)$$

3. Nous avons vu que l'espace des croyances est courbé (sphérique) et cette courbure fait apparaître un phénomène qui n'existe pas en géométrie euclidienne : l'**holonomie**. L'holonomie est une conséquence fondamentale de la courbure (métrique de Fisher-Rao). Prenons un vecteur v représentant une "préférence" ou une stratégie (par exemple un vecteur d'investissement, mathématiquement un vecteur dans l'espace tangent). Si nous transportons ce vecteur "parallèlement" (c'est-à-dire en essayant de rester cohérent localement) le long d'une courbe fermée de croyances (une suite d'arguments), la question est : revient-il à son état initial ? Nous allons voir que la réponse est non. Le contexte traversé a modifié l'orientation du vecteur.

Considérons un univers à $n = 3$ états correspondant à trois projets concurrents $\{A, B, C\}$. Supposons qu'un investisseur parte d'une position de neutralité (ignorance) :

$$p^{(0)} := \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3} \right)$$

Sa stratégie d'investissement initiale est donnée par un vecteur (que l'on aura centré au préalable) $x^{(0)} \in T_{p^{(0)}} \mathring{\Delta}_3$. Supposons qu'il souhaite initialement désinvestir légèrement de A et B pour favoriser C :

$$x^{(0)} := (-1, -1, 2)$$

L'investisseur assiste à une série de présentations sur plusieurs semaines qui modifient temporairement sa perception du marché (la distribution p), avant de revenir à la neutralité pour prendre sa décision finale. Considérons le cycle de croyances suivant (mathématiquement le triangle géodésique) :

- Présentation 1 : Le marché semble favoriser fortement le projet A, cette présentation modifie sa croyance en :

$$p^{(1)} := (0, 8; 0, 1; 0, 1)$$

- Présentation 2 : Le marché change et semble favoriser fortement le projet B cette fois, sa croyance devient :

$$p^{(2)} := (0, 1; 0, 8; 0, 1)$$

- Présentation 3 : L'investisseur revient à sa position neutre initiale pour décider :

$$p^{(3)} := p^{(0)} := \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3} \right)$$

Calculer sous Python en utilisant la formule démontrée du transport parallèle les changements subis sur sa stratégie d'investissement :

- Calculer $x^{(1)}$: le transport parallèle de $x^{(0)}$ le long de la géodésique reliant $p^{(0)}$ à $p^{(1)}$.
- Calculer $x^{(2)}$: le transport parallèle de $x^{(1)}$ le long de la géodésique reliant $p^{(1)}$ à $p^{(2)}$.
- Calculer $x^{(3)}$: le transport parallèle de $x^{(2)}$ le long de la géodésique reliant $p^{(2)}$ à $p^{(0)}$.

Comparer $x^{(3)}$ et $x^{(0)}$. Calculer l'angle entre ces deux vecteurs (dans le sens du produit scalaire euclidien). Refaite le même calcul en supposant cette fois qu'il ait vu la présentation 2 avec la présentation 1. Comparer le résultat obtenu. Analyser.



Pause épistémologique : La Non-Commutativité de l'Information (Effet d'Ordre). En logique classique, l'accumulation d'information est commutative : $(A \text{ et } B)$ est strictement équivalent à $(B \text{ et } A)$. Cependant, la psychologie cognitive, notamment via les travaux de Tversky et Kahneman sur l'**Effet de Cadrage (Framing Effect)**, montre que l'ordre de présentation des arguments modifie la décision finale. L'holonomie montre que ceci n'est pas une "erreur" du cerveau, mais une propriété géométrique intrinsèque de l'apprentissage. Le vecteur "Stratégie" garde la mémoire de la courbure traversée. Avoir cru temporairement que "le projet A était génial" avant de se raviser a tordu l'espace de décision différemment que si l'on n'avait jamais cru en A.